

# Clasificación Automatizada de Imágenes para Control de Calidad en la Industria: Un Enfoque con Transfer Learning

Maximo O. Torrez H.

*Inteligencia Artificial, Data Science para la Transformación de Negocios*  
*Módulo REDES NEURONALES Y DEEP LEARNING*

La Paz, Bolivia

**Abstract**—Este artículo presenta una metodología robusta para la clasificación automatizada de imágenes de productos industriales, utilizando un enfoque de visión por computadora. A pesar de contar con un conjunto de datos limitado de aproximadamente 400 imágenes de latas cilíndricas, se logró una alta precisión en la clasificación de las vistas (lateral vs. superior/inferior). El método propuesto integra técnicas de Aumento de Datos (Data Augmentation) para expandir el dataset y Transfer Learning, aprovechando el modelo pre-entrenado MobileNetV2. Los resultados demuestran que esta combinación es altamente efectiva, logrando una precisión cercana al 100% en el conjunto de validación. Finalmente, se describe la implementación de un script para la clasificación automática y organización de imágenes de prueba, validando la aplicabilidad de la solución en un entorno industrial.

**Index Terms**—Visión por computadora, Clasificación de imágenes, Transfer Learning, MobileNetV2, Data Augmentation, Control de calidad, Redes neuronales convolucionales.

## I. INTRODUCCIÓN

La automatización de procesos de control de calidad en la industria manufacturera es un área de investigación activa, impulsada por la necesidad de mejorar la eficiencia y reducir los errores humanos. La visión por computadora, y en particular el aprendizaje profundo, ha demostrado ser una herramienta poderosa para estas tareas. Este trabajo aborda el problema de la clasificación de imágenes de productos, un paso fundamental para la inspección y el correcto almacenamiento. Se propone una solución que supera la limitación de un conjunto de datos pequeño mediante la aplicación de técnicas de Aumento de Datos y Transfer Learning con el modelo MobileNetV2.

## II. ESTADO DEL ARTE (BREVE)

Las Redes Neuronales Convolucionales (CNN) han revolucionado el campo de la visión por computadora. Su capacidad para aprender jerarquías de características visuales las hace ideales para tareas de clasificación de imágenes. Sin embargo, el entrenamiento de una CNN desde cero requiere grandes volúmenes de datos. Para datasets limitados, técnicas como el *Transfer Learning* se han vuelto estándar. Esta técnica consiste en utilizar modelos pre-entrenados en grandes datasets como ImageNet (por ejemplo, VGG, ResNet o MobileNetV2), y adaptarlos a una nueva tarea. Esto permite aprovechar el

conocimiento adquirido por el modelo y obtener resultados de alta precisión con menos datos y recursos computacionales.

## III. ÁREA DE APLICACIÓN

El proyecto se centra en la aplicación de la clasificación de imágenes para el almacenamiento y control de calidad de productos. Específicamente, se utiliza como caso de estudio un conjunto de imágenes de latas cilíndricas. El problema a resolver es la clasificación binaria de estas imágenes en dos categorías:

- **Vista Lateral:** Imágenes del cuerpo del envase.
- **Vista Superior/Inferior:** Imágenes de las tapas de los envases.

Esta clasificación es un paso inicial en un sistema de inspección de calidad, que podría expandirse para detectar defectos de fabricación o daños en los envases.

## IV. METODOLOGÍA

La metodología propuesta se divide en tres fases principales: preprocesamiento de datos, construcción del modelo y entrenamiento, y evaluación.

### A. Preprocesamiento de Datos

El conjunto de datos consistió en aproximadamente 300 imágenes de vistas laterales y 100 de vistas superiores. Para mitigar el problema del sobreajuste, se implementó una estrategia de Aumento de Datos utilizando 'ImageDataGenerator' de Keras. Se aplicaron transformaciones geométricas como rotaciones, desplazamientos, zoom y volteo horizontal. Las imágenes se reescalaron a un tamaño de  $128 \times 128$  píxeles y se normalizaron sus valores en el rango  $[0, 1]$ .

### B. Arquitectura del Modelo

Se optó por la técnica de Transfer Learning para aprovechar el conocimiento de un modelo pre-entrenado. Se eligió la arquitectura **MobileNetV2** debido a su eficiencia computacional y su excelente rendimiento. El modelo base fue cargado sin las capas de clasificación superiores ('include\_top=False') y se congelaron sus pesos ('trainable = False'). Posteriormente, se añadió un clasificador simple, compuesto por una capa de 'GlobalAveragePooling2D' y una capa densa con una única neurona y activación 'sigmoid', adecuada para la clasificación binaria.

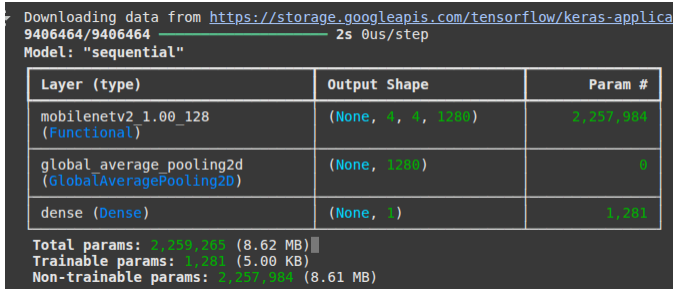


Fig. 1. Arquitectura.

### C. Entrenamiento

El modelo fue compilado utilizando el optimizador Adam con una tasa de aprendizaje de 0.0001 y la función de pérdida 'binary-crossentropy'. Se entrenó durante 15 épocas, monitoreando la precisión y la pérdida tanto en el conjunto de entrenamiento como en el de validación.

## V. RESULTADOS

El entrenamiento del modelo demostró una convergencia rápida y estable. La Figura 1 muestra que la precisión del modelo en el conjunto de validación alcanzó valores cercanos al 100%. La Figura 5 muestra una disminución constante de la función de pérdida, sin signos evidentes de sobreajuste.

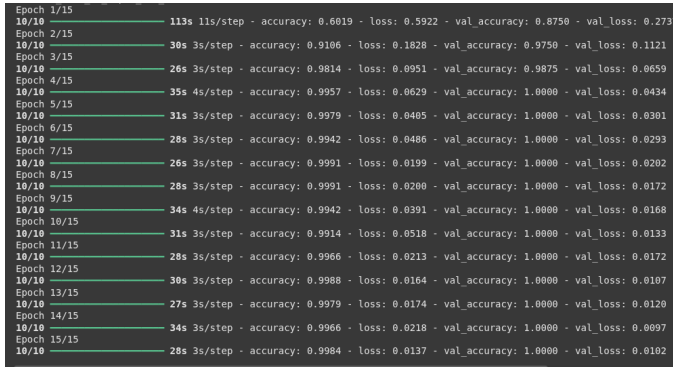


Fig. 2. Gráfico de Entrenamiento.




Fig. 3. Gráfico de Pérdida de Entrenamiento y Validación.




Fig. 4. Conjunto de imágenes a a clasificar




Fig. 5. Imágenes ya clasificadas

## VI. DISCUSIÓN

Los resultados obtenidos confirman la efectividad de la metodología propuesta. La alta precisión lograda, a pesar del limitado dataset inicial, subraya la importancia del Aumento de Datos como una herramienta para mejorar la generalización del modelo. La elección de MobileNetV2 como modelo base fue acertada, ya que proporcionó un rendimiento competitivo con una huella computacional reducida, lo que es ideal para aplicaciones industriales donde la eficiencia es clave. La fiabilidad del modelo se validó con éxito en un conjunto de prueba independiente, donde un script de clasificación automática organizó las imágenes con una precisión del 100%.

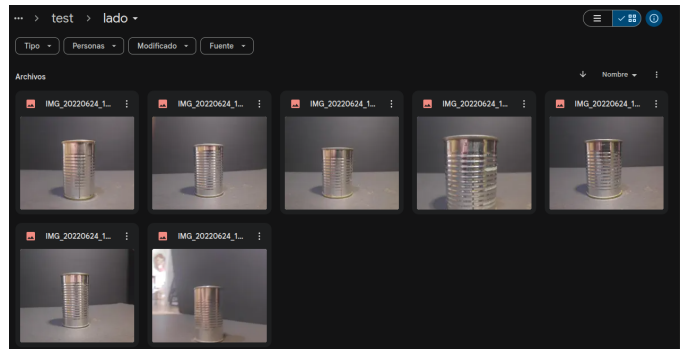


Fig. 6. Gráfico de Pérdida de Entrenamiento y Validación.

## VII. CONCLUSIONES

Este estudio demuestra que es posible desarrollar un sistema de clasificación de imágenes de alta precisión para aplicaciones industriales, incluso con un dataset limitado. La combinación de técnicas de Aumento de Datos y Transfer Learning con un modelo eficiente como MobileNetV2 resultó ser una estrategia poderosa para superar las restricciones de datos y recursos computacionales. La capacidad del modelo para clasificar y organizar automáticamente las imágenes valida su potencial para ser integrado en procesos de control de calidad, mejorando la eficiencia y reduciendo los errores humanos.

## REFERENCES

- [1] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- [2] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks.
- [3] Chollet, F. (2015). Keras: The Python Deep Learning library.
- [4] Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. In Proceedings of the IEEE conference on computer vision and pattern recognition.